Datatypes GGM v3.0.0 naar MIM: mapping

Status: doorgevoerd in het EA-model op 4 november 2026 met tools/fix_datatypes_mim.py (3.267 attributen). De vervolgstappen onder "Open punten" staan nog open.

Context

Het GGM v3.0.0 typeert attributen nog grotendeels in de RSGB/StUF-notatie (AN80, N2, int, datum, Text, string, Bedrag, GUID …). De classifier van die attributen wijst in Enterprise Architect meestal al naar het pakket *MIM11 Primitieve datatypen* (AN80 → CharacterString, int → Integer, datum → Date), maar de zichtbare typetekst niet, en de lengte zit in de typetekst en in het EA-veld *Length* in plaats van in de MIM-tag *Lengte*. Alle generatoren werken op de typetekst: de codegeneratietemplates (DDL) en crunch_uml (markdown, LOD, Excel, vertalingen).

De omzetting maakt de typetekst gelijk aan het MIM-datatype en zet lengte, eenheid en patroon in de MIM-tags. De informatie die nu in de typetekst zit, gaat dus niet verloren maar verhuist naar de plek waar MIM hem verwacht.

Uitgangspunten

- Alleen de elf MIM-standaardtypen (CharacterString, Integer, Real, Decimal, Boolean, Date, DateTime, Year, Day, Month, URI), aangevuld met drie eigen primitieve datatypen (Blob, OnvolledigeDatum, Tijd), één gestructureerd datatype (NEN3610ID) en de GML3-geometrieën (GM_Point enz.).
- De typetekst van een attribuut is altijd gelijk aan de naam van de classifier.
- **Lengte**: tag *Lengte* met een kaal getal, gelezen als maximumlengte ("80"). Bij Decimal "cijfers,decimalen" ("10,2"). De EA-velden *Length*, *Precision* en *Scale* worden ook gevuld, voor de DDL-templates.
- **Eenheid**: tag *Eenheid* ("EUR" bij bedragen).
- **Patroon**: tag *Formeel patroon* (reguliere expressie) bij GUID, e-mail, IBAN en telefoonnummer.
- **Ja/nee-velden**: MIM Boolean. Alleen INDIC en StdIndJN blijven een eigen enumeratie (keuze beheerder).
- Real wordt niet gebruikt; double en decimal worden Decimal.

Mappingtabel

Nu in het model	Aantal	Wordt	Tags en velden
AN80, AN200, AN40, AN20, AN50, AN255, AN100, AN250, … en A1	1.287	CharacterString	Lengte = n; EA Length = n
Text, Tekst, string, varchar, char, AN zonder getal, CharacterString	404	CharacterString	geen lengte, tenzij EA Length of tag al gevuld is
Date, datum	761	Date	
DateTime, DatumTijd	110	DateTime	
int, Integer, Number	481	Integer	
N2, N3, N4, N5, N6, N8, N9, N11, N12	106	Integer	Lengte = n
N10.2	1	Decimal	Lengte 10,2; Precision 10, Scale 2
double, decimal	10	Decimal	
Boolean, Bool	315	Boolean	
Boolean als enumeratie Ja/Nee/Onbekend/Leeg (Enumeratiesoort, Model BAG)	22	Boolean	Mogelijk geen waarde = Ja; de twee enumeraties *Boolean* vervallen
StdIndJN (enumeratie Ja/Nee)	43	StdIndJN, blijft eigen enumeratie	8 attributen krijgen alsnog de classifier

Nu in het model	Aantal	Wordt	Tags en velden
INDIC	4	INDIC, nieuwe eigen enumeratie (Ja/Nee) in Enumeratiesoort	
Bedrag, bedrag, Geldbedrag	167	Decimal	Lengte 10,2; Eenheid EUR; Precision 10, Scale 2
GUID	50	CharacterString	Lengte 36; Formeel patroon UUID
Email, IBAN, telefoonnummer	4	CharacterString	Formeel patroon per soort; IBAN Lengte 34, telefoonnummer Lengte 10
URL, URI	2	URI	
JAAR, Jaar, Dag, Maand	2	Year, Day, Month	GGM-varianten vervallen (Dag en Maand zijn ongebruikt)
Time	3	Tijd, nieuw eigen «Primitief datatype» in GGM Datatypes	crunch_uml mapt "tijd" al naar xsd:time
BLOB, Image	5	Blob, blijft eigen «Primitief datatype»	
OnvolledigeDatum	16	OnvolledigeDatum, blijft eigen «Primitief datatype»	Formeel patroon op het datatype: jjjjmmdd, 00 voor onbekend
NEN3610ID, CompositeID	29	NEN3610ID als «Gestructureerd datatype» (namespace, lokaalID, versie)	CompositeID gaat erin op; de foute classifier Integer wordt hersteld
Point, punt, Spatial, Surface, Vlak, MultiSurface, Curve, Lijn, MultiCurve, MultiPoint, Object	115	GM_Point, GM_Surface, GM_MultiSurface, GM_Curve, GM_MultiCurve, GM_MultiPoint, GM_Object (GML3, ongewijzigd)	alleen typetekst gelijk aan classifier
"1" (hoek), "2" (som), "ntatie" (oriëntatie), Enum	12	Decimal, Decimal, Decimal, handmatig	
Type, TypePlus, Materiaal, Leverancier, … zonder classifier (vooral Model IMBOR)	292	buiten deze omzetting	later koppelen aan enumeraties (IMBOR-werk)
Enumeraties, objecttypen, gestructureerde datatypen als type	379	ongewijzigd	

Aantallen: attributen in v3.0.0 op 4 november 2026 vóór de omzetting (4.585, exclusief 4.236 enumeratiewaarden). Bij de doorvoering waren het er 4.618 door 33 nieuwe attributen uit de Financiën-proposals van diezelfde middag; het rapport tools/mim-datatypes-omzetting.md heeft de definitieve aantallen.

Formele patronen

Soort	Formeel patroon
GUID (UUID zonder accolades)	`^[0-9a-fA-F]{8}-[0-9a-fA-F]{4}-[0-9a-fA-F]{4}-[0-9a-fA-F]{4}-[0-9a-fA-F]{12}$`
E-mail	`^[^@\s]+@[^@\s]+\.[^@\s]+$`
IBAN	`^[A-Z]{2}[0-9]{2}[A-Z0-9]{1,30}$`
Telefoonnummer (10 cijfers, conform de huidige GGM-definitie)	`^[0-9]{10}$`
OnvolledigeDatum (jjjjmmdd, 00 voor onbekend)	`^[0-9]{4}([0-9]{2}|00)([0-9]{2}|00)$`

Wat verandert er voor de generatoren

- **crunch_uml, import**: `primitive` krijgt de MIM-naam in plaats van AN80; de tag *Lengte* komt als `lengte` mee. Geen aanpassing nodig.
- **crunch_uml, LOD**: `map_datatype` kent characterstring, integer, decimal, boolean, date, datetime, uri, year en tijd al. De maximumlengte komt na de omzetting uit `mim:lengte` (sh:maxLength) in plaats van uit "AN80". Controlegetal: de shapes-ttl van v3.0.0 heeft nu 1.317 sh:maxLength; dat mag niet dalen. Eigen primitieve datatypen (Blob, OnvolledigeDatum, Tijd) worden mim:PrimitiefDatatype met sh:datatype.
- **crunch_uml, markdown (tools/ggm_markdown.j2)**: toont alleen `getDatatype()`; de lengte erbij tonen, bijvoorbeeld "CharacterString (80)".
- **crunch_uml, JSON-schema en SQLAlchemy** (niet in de GGM-pijplijn): kennen geen decimal en gebruiken `lengte` niet; de $def *bedrag* vervalt. Apart op te pakken.
- **Codegeneratietemplates (EA, Tables_Transform_Template › Attribute__RSGB)**: vertakt op de typetekst. Nieuwe takken nodig voor characterstring (varchar met de attribuutlengte, zonder lengte text), decimal (precision en scale uit de EA-velden), year/day/month, uri en nen3610id. Bug: na TO_LOWER matchen de vergelijkingen op "CharacterString", "Geldbedrag" en "StdIndJN" nooit. De takken an, bedrag en guid kunnen als terugval blijven.
- **Excel-export**: de kolom *primitive* verandert van inhoud (AN80 → CharacterString, lengte in de kolom *lengte*).
- **Vertalingen**: volgen vanzelf na `task translate`.
- **Documentatie**: de datatypelijst in docs/generatie.md en het cookbook herschrijven naar de MIM-namen.

Open punten

- NEN3610ID als gestructureerd datatype volgens NEN 3610 (voorkeur) of als CharacterString met formeel patroon; het gestructureerde datatype raakt de DDL-templates.
- De stereotypen «Primitief datatype» en «Gestructureerd datatype» (MIM-profiel) op de eigen datatypen, in plaats van «Interface».
- De 292 losse typenamen zonder classifier (vooral Model IMBOR en Beheer Openbare Ruimte).
- Het verwijderen van de nu onverwezen datatypen (Bedrag, Dag, Jaar, Maand, Email, GUID, IBAN, Telefoonnummer, Geldbedrag, CompositeID, de twee enumeraties Boolean) gebeurt pas na controle in EA; de enumeratie Boolean staat nog op 10 diagrammen, CompositeID op 6.
- Zes attributen met typetekst "Enum" (Leerroute, Rijbewijs/Certificaat) zijn handmatig te typeren.